Progetto per l'esame di Programmazione di applicazioni di Data Intensive

di: Luca Pesaresi

Il progetto consiste nell'analizzare i dati recuperati dal sito IMDB Internet Movies DataBase) contenente un archivio di informazioni relativi ai titoli di film, serie tv, cortometraggi, ect. Per effettuare l'analisi mi sono servito di due dataset

- `imdb_movies.csv` recuperato dal sito https://www.imdb.com/interfaces/ (https://www.imdb.com/interfaces/)
- `user_ratings_imdb.csv` recuperato dal sito https://ieee-dataport.org/open-access/imdb-users-ratings-dataset (https://ieee-dataport.org/open-access/imdb-users-ratings-dataset)

L'obiettivo è quello di svolere un'unalisi di recommendation, in cui dato un utente venga restituita una lista dei titoli suggeriti con valutazioni più alte

Librerie

In [1]:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

In [2]:

```
lib = !pip list -v | grep [Ss]urprise
if not lib:
  !pip install surprise
```

Caricamento dei dati

Carichiamo i due dataset

In [3]:

```
movies = pd.read_csv('imdb_movies.csv')
```

In [4]:

```
movies.head(3)
```

Out[4]:

	tconst	type	title	isAdult	year	minutes	genres
0	tt0000001	short	Carmencita	0	1894	1	Documentary,Short
1	tt0000002	short	Le clown et ses chiens	0	1892	5	Animation,Short
2	tt0000003	short	Pauvre Pierrot	0	1892	4	Animation,Comedy,Romance

In [5]:

```
user_ratings = pd.read_csv('user_ratings_imdb.csv')
```

In [6]:

```
user_ratings.head()
```

Out[6]:

	user_id	tconst	rating
0	ur0000001	tt1144884	4
1	ur0000002	tt0119237	2
2	ur0000002	tt0120741	5
3	ur0000002	tt0120746	7
4	ur0000002	tt0129387	7

Significato delle variabili

imdb_movies

- `tconst` : indicizza i titoli del dataset.
- `type` : indica la tipologia di video: film, cortometraggio, serie tv, ect.
- `title` : indica il titolo del video.
- `isAdult` : indica se la visione è ristretta ad un pubblico adulto (1) altrimenti (0).
- `year` : indica l'anno di rilascio del video, o nel caso di una serie tv l'anno in cui è iniziata.
- `minutes` : riporta il minutaggio del video.
- `genres` : indica il genere rispettivo del video.

user_ratings

- `user_id` : indicizza le valutazioni dei ripettivi utenti del dataset.
- `tconst` : indicizza il relativo titolo valutato.
- `rating` : valutazione del video.

Preparazione dei dati

Vengono sostuiti tutti i valori vuoti con una stringa vuota

In [7]:

```
movies.dropna(inplace=True)
movies = movies.loc[movies["year"] != '\\N']
movies = movies.loc[movies["minutes"] != '\\N']
movies = movies.loc[movies["genres"] != '\\N']
movies.reset_index(drop=True, inplace=True)
```

Si convertono le colonne numeriche nel formato intero.

In [8]:

```
movies["year"] = movies["year"].astype(int)
movies["minutes"] = movies["minutes"].astype(int)
```

Si rimuovono tutte i dati relativi ai titoli che devono ancora uscire negli anni a venire.

In [9]:

```
import datetime
year = datetime.datetime.now().year
movies = movies[movies["year"] < year]
```

In [10]:

```
movies.size
```

Out[10]:

```
7882602
```

Analisi espolorativa dei dati

Si genera una distribuzione dei titoli a partire dal 1950 ad oggi

In [11]:

```
movies.loc[movies["year"] > 1949]["year"].value_counts().sort_index().plot.bar(figsize=
(20,5));
```

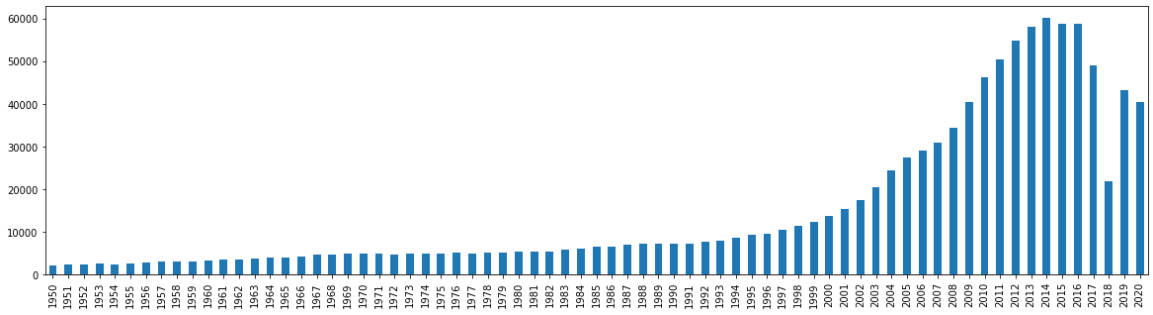

Solamente una piccola percentuale dei titoli è riservata ad un pubblico adulto

In [12]:

```
100*round(movies["isAdult"].value_counts(normalize=True),2)
```

Out[12]:

```
0    94.0
1     6.0
Name: isAdult, dtype: float64
```

Dal grafico si notano i generi più di tendenza

In [13]:

```
movies["genres"].value_counts(ascending=False)[:20].plot.pie(figsize=(10,10));
```

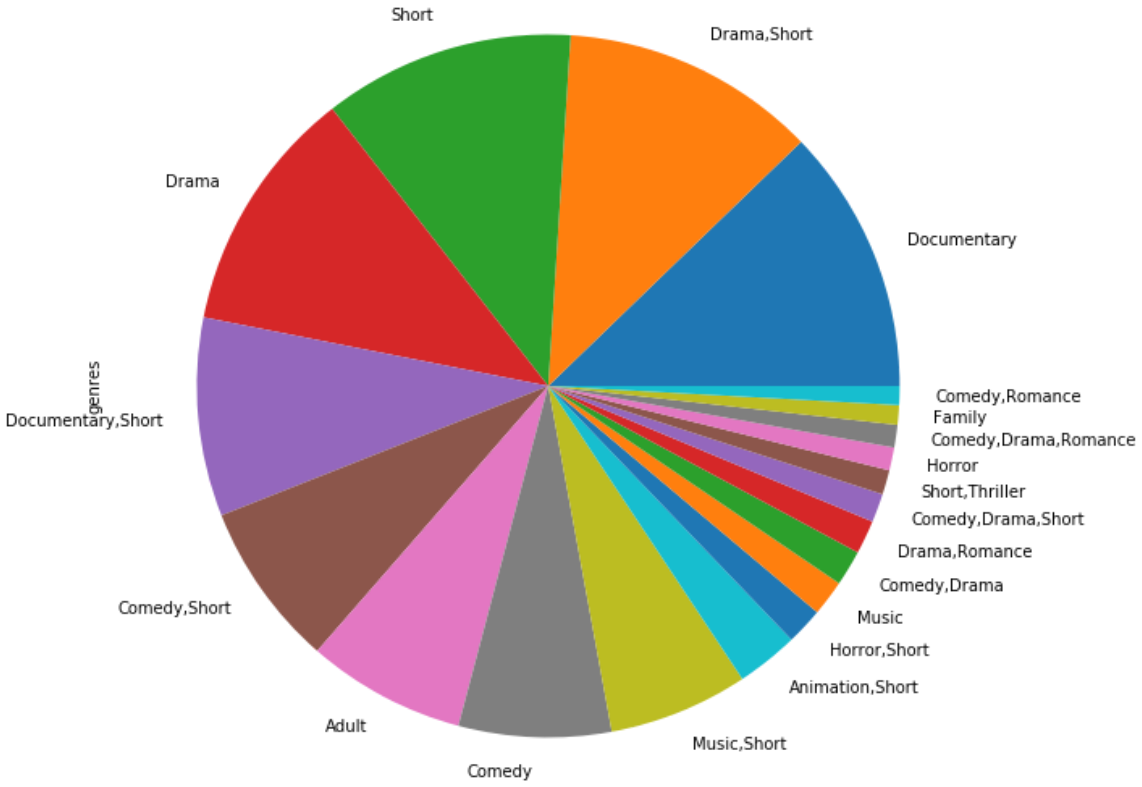

In [14]:

```
user_ratings.describe()
```

Out[14]:

	rating
count	4.669820e+06
mean	6.557848e+00
std	2.532589e+00
min	1.000000e+00
25%	5.000000e+00
50%	7.000000e+00
75%	9.000000e+00
max	1.000000e+01

Confronto tra le varie tipologie di video.

In [15]:

```
movies["type"].value_counts().plot.bar();
```

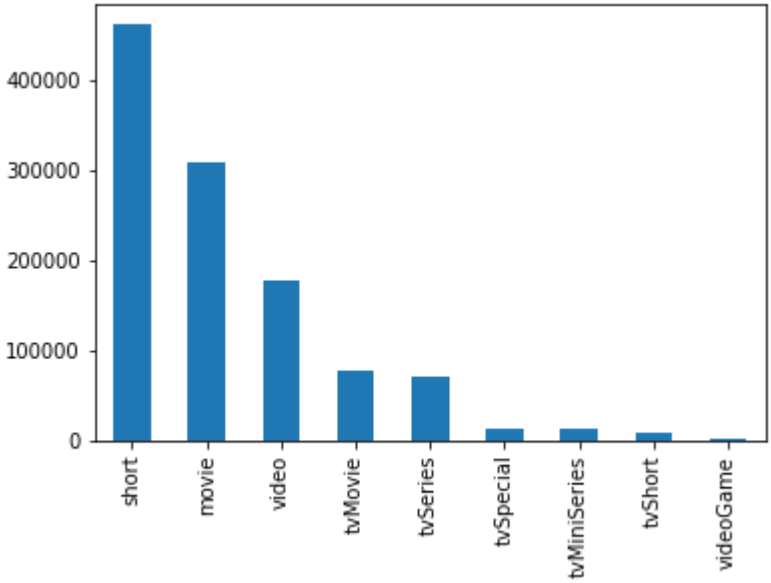

Il dataframe user_ratings contiene le valutazioni per un campione di 1_499_238 utenti per 351_109 titoli con un range di 10 voti

In [16]:

```
user_ratings.nunique()
```

Out[16]:

```
user_id    1499238
tconst      351109
rating          10
dtype: int64
```

La distribuzione dei voti secondo il range di valutazioni

In [17]:

```
pd.DataFrame(user_ratings["rating"].value_counts().sort_index()).T
```

Out[17]:

	1	2	3	4	5	6	7	8	9	10
rating	199834	262117	278304	290156	364741	550629	702626	814896	725833	480684

In [18]:

```
user_ratings["rating"].value_counts().sort_index().plot.bar(figsize=(20, 5));
```

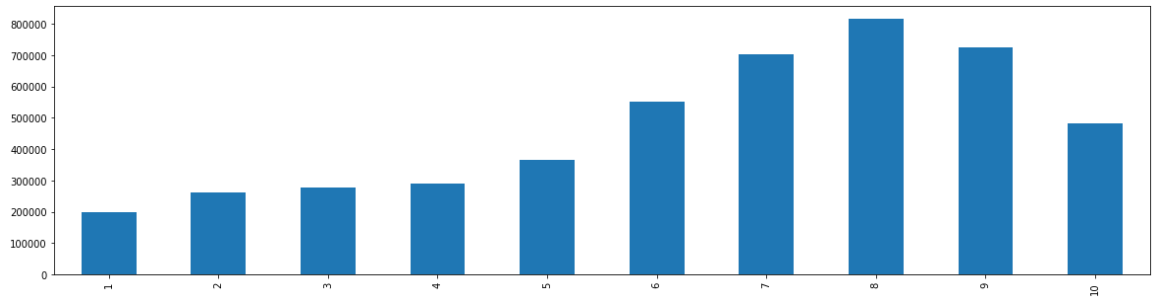

Si definisce una funzione per limitare le occorrenze al fine di semplificare la visualizzazione dei dati

In [19]:

```
def lim_df(df, lim):
    df.groupby("user_id").head(lim)
    user_id_max = df["user_id"].unique()[:lim][lim-1]
    last_element = (np.where(df["user_id"] == user_id_max))[0]
    last_element = last_element[len(last_element)-1]
    return df[:last_element]
```

In [20]:

```
lim_user = lim_df(user_ratings, 50)
```

Si vuole ottenere una distribuzione sul numero di valutazioni medie per utente e il numero di valutazioni medie per film

In [21]:

```
lim_user.groupby("user_id")["rating"].mean().plot.bar(figsize=(20,5));
```

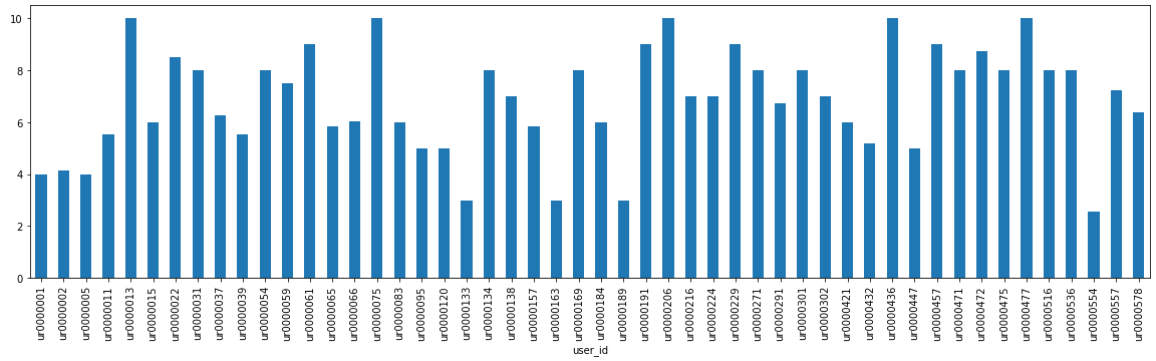

In [22]:

```
lim_movie = user_ratings.head(50)
lim_movie.groupby("tconst")["rating"].mean().plot.bar(figsize=(20,5));
```

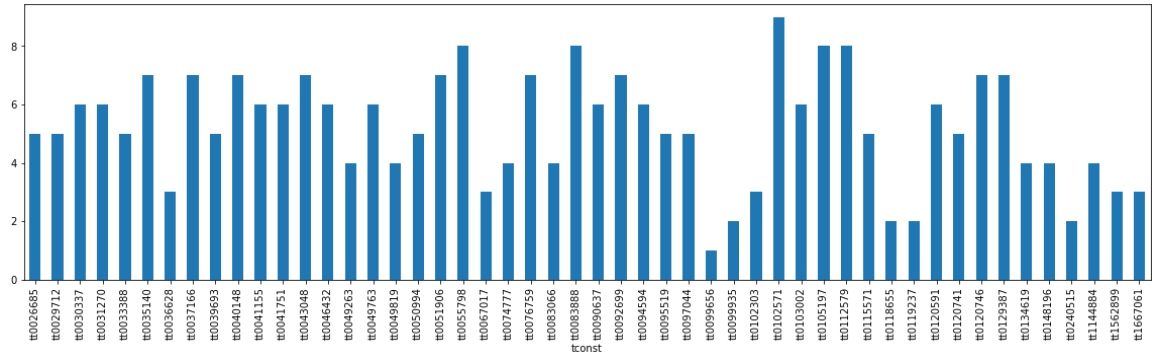

Dato che le valutazioni degli utenti non sono note all'interno del dataframe `movies`, si ricava un dataframe contenente le medie delle valutazioni per ogni titolo del dataframe `user_ratings`.

In [23]:

```
ur = user_ratings
means = ur.groupby("tconst")["rating"].mean()
index = pd.Series(means.index.values, name='tconst')
values = pd.Series([round(i,1) for i in means.values], name="rating")
movies_avg = pd.concat([index, values], axis=1)
movies_avg.head()
```

Out[23]:

	tconst	rating
0	tt0000001	6.0
1	tt0000003	7.1
2	tt0000005	7.0
3	tt0000007	6.0
4	tt0000008	7.0

Si unisce il dataframe appena creato con il dataframe movies per aggiungere una valutazione generale per ogni titolo

In [24]:

```
movies_rated = movies.merge(movies_avg, left_on = 'tconst', right_on = 'tconst')
movies_rated.head()
```

Out[24]:

	tconst	type	title	isAdult	year	minutes	genres	rating
0	tt0000001	short	Carmencita	0	1894	1	Documentary,Short	6.0
1	tt0000003	short	Pauvre Pierrot	0	1892	4	Animation,Comedy,Romance	7.1
2	tt0000005	short	Blacksmith Scene	0	1893	1	Comedy,Short	7.0
3	tt0000007	short	Corbett and Courtney Before the Kinetograph	0	1894	1	Short,Sport	6.0
4	tt0000008	short	Edison Kinetoscopic Record of a Sneeze	0	1894	1	Documentary,Short	7.0

Si associano i vari titoli alle relative valutazioni di ogni singolo utente

In [25]:

```
ur = user_ratings.merge(movies_rated[["tconst","title"]], left_on = 'tconst', right_on
= 'tconst')
ur.rename(columns = {'rating':'user_rating'}, inplace = True)
ur = ur[["user_id","title","user_rating"]].sort_values("user_id")
ur.reset_index(drop=True, inplace=True)
ur.head()
```

Out[25]:

	user_id	title	user_rating
0	ur0000001	The Final Destination	4
1	ur0000002	The Mask of Zorro	7
2	ur0000002	There's Something About Mary	7
3	ur0000002	Disturbing Behavior	4
4	ur0000002	Freddy Got Fingered	2

In [26]:

```
ur.size
```

Out[26]:

```
11923593
```

Il dataframe è troppo voluminoso quindi si rimuovono tutti i duplicati e si limita la dimensione a 500 utenti

In [27]:

```
lim_ur = ur.drop_duplicates(subset=['user_id','title'], keep='first')
lim_ur = lim_df(lim_ur, 250)
```

In [28]:

```
lim_ur.size
```

Out[28]:

7284

Si creano due insiemi per l'addestramento e la validazione dei dati

In [29]:

```
from sklearn.model_selection import train_test_split
data_train, data_test = train_test_split(lim_ur, test_size=1/3, random_state=42)
```

Viene impostato come indice del frame la coppia di colonne `user e title`

In [30]:

```
data_train.set_index(["user_id","title"], inplace=True)
```

In [31]:

```
data_train.head()
```

Out[31]:

		user_rating
user_id	**title**	
ur0000950	**Terminal Velocity**	8
ur0002578	**Inside Man**	9
ur0001220	**The Ghost and Mrs. Muir**	7
ur0000011	**Maid in Manhattan**	7
ur0002746	**Out of Time**	6

Si procede con l'estrazione di una matrice utenti per titoli dove:

- ogni riga corrisponde ad un utente u
- ogni colonna corrisponde ad un titolo i
- ogni cella contiene il voto dato dall'utente u a al titolo t

Si esegue l'operazione di pivoting `unstack` sull'unica colonna rimasta `user_rating` per portare i titoli dall'indice delle righe a quello delle colonne

In [32]:

```
train_ratings = data_train["user_rating"].unstack("title")
```

In [33]:

```
train_ratings.iloc[:5, :5]
```

Out[33]:

title user_id	'Neath the Arizona Skies	'Tis Autumn: The Search for Jackie Paris	10 pesos	100 Million BC	102 Dalmatians
ur0000001	NaN	NaN	NaN	NaN	NaN
ur0000002	NaN	NaN	NaN	NaN	NaN
ur0000005	NaN	NaN	NaN	NaN	NaN
ur0000011	NaN	NaN	NaN	NaN	NaN
ur0000013	NaN	NaN	NaN	NaN	NaN

Creazione dei modelli

Raccomendation User-based Collaborative Filtering con similarità coseno

- La **recommendation user-based**, pemette la previsione di un voto $\hat{r}_{u,t}$ per un titolo t da un utente u in base ai voti dati da altri utenti a t, pesati proporzionalmente alla loro somiglianza con l'utente u.
- Per calcolare la somiglianza si usa la **similarità coseno** $\mathrm{sim}(u, v)$ che trova l'angolo formato tra tra due vettori che in questo caso sono le valutazioni tra i due utenti u e v
- Nell'approccio **collaborative filtering** si usa la similarità coseno confrontando i voti dati da entrambi gli utenti

In [34]:

```
R = train_ratings.fillna(0).values
R[:5,:5]
```

Out[34]:

```
array([[0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0.],
       [0., 0., 0., 0., 0.]])
```

In [35]:

```
P = train_ratings.notna().values
P[:5,:5]
```

Out[35]:

```
array([[False, False, False, False, False],
       [False, False, False, False, False],
       [False, False, False, False, False],
       [False, False, False, False, False],
       [False, False, False, False, False]])
```

Si procede calcolando numeratore e denominatore

In [36]:

```
cos_num = R @ R.T
```

In [37]:

```
P_and = P[:, None, :] & P[None, :, :]
R_com = P_and * R[:, None, :]
R_com_rss = np.sqrt(np.sum(np.square(R_com), 2))
cos_den = R_com_rss * R_com_rss.T
```

In [38]:

```
cos = cos_num / cos_den
cos[np.isnan(cos)] = 0
cos[:5, :5]
```

```
C:\Users\luca2\anaconda3\lib\site-packages\ipykernel_launcher.py:1: Runtim
eWarning: invalid value encountered in true_divide
  """Entry point for launching an IPython kernel.
```

Out[38]:

```
array([[1., 0., 0., 0., 0.],
       [0., 1., 0., 0., 0.],
       [0., 0., 1., 0., 0.],
       [0., 0., 0., 1., 0.],
       [0., 0., 0., 0., 1.]])
```

Si definisce una funzione che dati gli indici utente u e titolo t venga restituito il voto predetto

In [39]:

```
def predict_from_all(u, t):
    other_users = list(np.where(P[:, t])[0])
    predicted_vote = (cos[u, other_users] @ R[other_users, t]) / cos[u, other_users].su
m()
    return predicted_vote if not np.isnan(predicted_vote) else R[P].mean()
```

In [40]:

```
predict_from_all(4, 1)
```

```
C:\Users\luca2\anaconda3\lib\site-packages\ipykernel_launcher.py:3: Runtim
eWarning: invalid value encountered in double_scalars
  This is separate from the ipykernel package so we can avoid doing import
s until
```

Out[40]:

```
6.484548825710754
```

Si eseguono le operazioni di indicizzazione sui dati di validazione

In [41]:

```
data_test.set_index(["user_id","title"], inplace=True)
val_ratings = data_test["user_rating"].unstack("title")
val_ratings = val_ratings.reindex_like(train_ratings)
```

Si creano due matrici

- R_val contenente i voti, uguali a 0 dove sono mancanti
- P_val matrice booleana che indica per quali coppie utente-oggetto è presente un voto

In [42]:

```
R_val = val_ratings.fillna(0).values
P_val = val_ratings.notna().values
```

Si definisce un vettore `val_actual` con tutti i voti definiti nel validation set

In [43]:

```
val_actual = R_val[P_val]
```

Si definisce una funzione che effettui le previsioni dei voti di tutte le coppie utente u, titolo t (che hanno già un voto val_actual) sui dati di validazione

In [44]:

```
def get_val_predictions(pred_func):
    return np.array([pred_func(u, t)
                     for u, t in zip(*np.where(P_val))])
```

In [45]:

```
val_predictions = get_val_predictions(predict_from_all)
```

```
C:\Users\luca2\anaconda3\lib\site-packages\ipykernel_launcher.py:3: Runtim
eWarning: invalid value encountered in double_scalars
  This is separate from the ipykernel package so we can avoid doing import
s until
```

In [46]:

```
val_predictions
```

Out[46]:

```
array([ 6.48454883,  6.48454883,  6.48454883,  6.48454883,  6.        ,
        9.48031469,  8.        ,  6.48454883,  6.48454883,  6.48454883,
        6.48454883,  6.48454883,  6.48454883,  6.48454883,  6.48454883,
        8.        ,  5.        ,  6.48454883,  6.48454883,  6.48454883,
        8.        ,  6.        ,  6.48454883,  7.        ,  6.48454883,
        5.        ,  6.48454883,  5.        ,  6.        ,  3.        ,
        9.        ,  9.        ,  6.48454883,  6.48454883,  6.48454883,
        6.48454883,  6.48454883,  6.48454883,  6.48454883,  6.48454883,
        6.        ,  6.48454883,  6.48454883,  6.48454883,  6.48454883,
        6.48454883,  6.48454883,  6.48454883,  9.        ,  6.48454883,
        6.48454883,  6.48454883,  6.48454883,  6.48454883,  6.48454883,
        6.48454883,  6.48454883,  7.        ,  6.48454883,  3.        ,
        6.        ,  5.        ,  6.48454883,  7.        ,  6.48454883,
        5.        ,  6.48454883,  6.48454883,  4.        ,  6.48454883,
        6.48454883,  6.48454883,  6.48454883,  9.        ,  9.        ,
        8.60924783, 10.        ,  6.48454883,  6.48454883,  7.        ,
        6.48454883,  6.48454883,  6.48454883,  6.48454883,  8.        ,
        8.        ,  6.48454883,  6.48454883,  7.        ,  4.        ,
        6.        ,  6.48454883,  8.        ,  4.        ,  3.        ,
        6.48454883,  6.48454883,  7.        ,  6.48454883,  8.        ,
        6.48454883,  6.48454883,  7.        ,  6.48454883,  6.48454883,
        6.48454883,  6.48454883,  6.48454883,  5.        ,  4.        ,
        3.        ,  6.48454883,  6.48454883, 10.        ,  6.48454883,
        6.48454883])
```

In [47]:

```
val_actual
```

Out[47]:

```
array([ 5.,  6.,  6.,  6.,  7.,  1.,  7.,  8.,  5.,  5.,  6.,  5.,  9.,
        3., 10.,  9.,  1.,  8.,  9.,  5.,  8.,  9.,  8.,  5.,  6.,  6.,
        6.,  4.,  8.,  4.,  7.,  6.,  9.,  7.,  6.,  6.,  7.,  4.,  6.,
        6.,  8.,  9.,  5.,  1.,  8.,  8.,  4.,  9.,  9., 10.,  6.,  8.,
       10., 10.,  9.,  2.,  6., 10.,  6.,  7.,  7.,  5.,  3.,  6.,  6.,
        6.,  4., 10.,  9.,  6.,  9.,  3.,  6., 10.,  9.,  6.,  7.,  8.,
        7.,  7.,  8., 10.,  9.,  9.,  3.,  8.,  9.,  8.,  7.,  3.,  8.,
        3.,  5.,  5.,  4.,  8.,  4.,  7.,  6.,  9.,  2.,  7.,  6.,  5.,
        3.,  6.,  7.,  5.,  2.,  8.,  9.,  4.,  1.,  9.,  9.,  9.])
```

Si definiscono le funzioni per il calcolo dell'errore quadratico medio RMSE e la media degli errori in valore assoluto MAE

In [48]:

```
def RMSE(actual, predicted):
    return np.sqrt(np.mean(np.square(predicted - actual)))
```

In [49]:

```
rmse = RMSE(val_actual, val_predictions)
```

In [50]:

```
def MAE(actual, predicted):
    return np.mean(abs(predicted - actual))
```

In [51]:

```
mae = MAE(val_actual, val_predictions)
```

Si definisce una funzione che restituisca un dataframe con i rispettivi errori di accuratezza per ogni modello.

In [52]:

```
def update_accuracy(df, model, rmse, mae):
    return df.append(pd.DataFrame([[model, rmse, mae]], columns=df.columns), ignore_ind
ex=True)
```

In [53]:

```
accuracy = pd.DataFrame(columns=["model","RMSE","MAE"])
accuracy = update_accuracy(accuracy, "cf", rmse, mae)
accuracy
```

Out[53]:

	model	RMSE	MAE
0	cf	2.440524	1.917943

Da quest'analisi possiamo notare che sia il MAE che l'RMSE sono poco accurati utilizzando questo tipo di approccio.

Surprise

Surprise è una libreria che premette di eseguire un'analisi di studio nella creazione e validazione di modelli di recommendation

In [54]:

```
from surprise import Dataset, Reader
from surprise.model_selection import train_test_split
reader = Reader(sep=",",rating_scale=(1, 10))
```

Si usa il dataframe limitato di user_ratings

In [55]:

```
data = Dataset.load_from_df(lim_ur, reader)
```

I dati vengono siddivisi in due insiemi: addestramento e validazione.

In [56]:

```
data_train, data_test = train_test_split(data, test_size=1/3, random_state=42)
```

Si estraggono alcune informazioni dall'insieme di addestramento

In [57]:

```
print('Media globale:\t\t{:.2f}'.format(data_train.global_mean))
print('Numore utenti:\t\t{}'.format(data_train.n_users))
print('Numore titoli:\t\t{}'.format(data_train.n_items))
print('Numore valutazioni:\t{}'.format(data_train.n_ratings))
```

```
Media globale:          6.52
Numore utenti:          202
Numore titoli:          1477
Numore valutazioni:     1618
```

Surprise KNNBasic con Similarità Coseno

Si crea un modello Surprise con la classe KNNBasic, usando similarità coseno e pearson, considerando una selezione di k utenti per ogni predizione, al fine di ottenere un modello migliore si usa anche la Cross-Fold-Validation

In [58]:

```
from surprise import KNNBasic
from surprise.accuracy import rmse, mae
from surprise.model_selection import cross_validate, KFold
```

In [59]:

```
kf = KFold(n_splits=5, shuffle=True, random_state=42)
```

In [60]:

```
model = KNNBasic(k=10, sim_options={"name": "cosine"})
cv_results = cross_validate(model, data, cv=kf)
```

```
Computing the cosine similarity matrix...
Done computing similarity matrix.
Computing the cosine similarity matrix...
Done computing similarity matrix.
Computing the cosine similarity matrix...
Done computing similarity matrix.
Computing the cosine similarity matrix...
Done computing similarity matrix.
Computing the cosine similarity matrix...
Done computing similarity matrix.
```

In [61]:

```
results = pd.DataFrame(cv_results)
results
```

Out[61]:

	test_rmse	test_mae	fit_time	test_time
0	2.144758	1.747347	0.004989	0.006979
1	2.112744	1.706264	0.004987	0.003988
2	2.259743	1.900585	0.003989	0.006981
3	2.328499	1.902456	0.005984	0.009975
4	2.189842	1.803907	0.003989	0.006986

Si esegue una predizione con predict tramite i parametri uid:indice degli user e iid:indice dei titoli

In [62]:

```
model.predict(1,1)
```

Out[62]:

```
Prediction(uid=1, iid=1, r_ui=None, est=6.4915079773546065, details={'was_
impossible': True, 'reason': 'User and/or item is unknown.'})
```

In [63]:

```
model.fit(data_train)
pred = model.test(data_test)
rmse(pred), mae(pred)
```

```
Computing the cosine similarity matrix...
Done computing similarity matrix.
RMSE: 2.2392
MAE:  1.8435
```

Out[63]:

```
(2.239226510623208, 1.8434525172061227)
```

In [64]:

```
rmse2 = cv_results["test_rmse"].mean()
mae2 = cv_results["test_mae"].mean()
accuracy = update_accuracy(accuracy, "cosine", rmse2, mae2)
```

Surprise KNNBasic con Similarità Pearson

Si ripete l'analisi con similarità pearson

In [65]:

```
from surprise.accuracy import rmse, mae
model = KNNBasic(k=10, sim_options={"name": "pearson"})
cv_results = cross_validate(model, data, cv=kf)
```

```
Computing the pearson similarity matrix...
Done computing similarity matrix.
Computing the pearson similarity matrix...
Done computing similarity matrix.
Computing the pearson similarity matrix...
Done computing similarity matrix.
Computing the pearson similarity matrix...
Done computing similarity matrix.
Computing the pearson similarity matrix...
Done computing similarity matrix.
```

In [66]:

```
pd.DataFrame(cv_results)
```

Out[66]:

	test_rmse	test_mae	fit_time	test_time
0	2.108197	1.722434	0.004983	0.009979
1	2.094392	1.694671	0.004987	0.007978
2	2.222896	1.869724	0.006982	0.017952
3	2.278373	1.860058	0.008976	0.015955
4	2.190523	1.812931	0.005982	0.008977

In [67]:

```
model.fit(data_train)
pred = model.test(data_test)
rmse(pred), mae(pred)
```

```
Computing the pearson similarity matrix...
Done computing similarity matrix.
RMSE: 2.2220
MAE:  1.8334
```

Out[67]:

```
(2.222049688022127, 1.8334172656381147)
```

In [68]:

```
rmse3 = cv_results["test_rmse"].mean()
mae3 = cv_results["test_mae"].mean()
accuracy = update_accuracy(accuracy, "pearson", rmse3, mae3)
```

Surprise KNNWithMeans con Similarità Coseno

Si ripete l'analisi precedente con similarità coseno con medie.

In [69]:

```
from surprise import KNNWithMeans
from surprise.accuracy import rmse, mae
model = KNNWithMeans(k=10, sim_options={"name": "cosine"})
cv_results = cross_validate(model, data, cv=kf)
```

```
Computing the cosine similarity matrix...
Done computing similarity matrix.
Computing the cosine similarity matrix...
Done computing similarity matrix.
Computing the cosine similarity matrix...
Done computing similarity matrix.
Computing the cosine similarity matrix...
Done computing similarity matrix.
Computing the cosine similarity matrix...
Done computing similarity matrix.
```

In [70]:

```
model.fit(data_train)
pred = model.test(data_test)
rmse(pred), mae(pred)
```

```
Computing the cosine similarity matrix...
Done computing similarity matrix.
RMSE: 2.2527
MAE:  1.8513
```

Out[70]:

```
(2.2526520775507883, 1.8513406850633651)
```

In [71]:

```
pd.DataFrame(cv_results)
```

Out[71]:

	test_rmse	test_mae	fit_time	test_time
0	2.164688	1.757042	0.009971	0.019948
1	2.130822	1.708233	0.017953	0.006981
2	2.271511	1.900351	0.024933	0.007978
3	2.353164	1.908550	0.014961	0.006982
4	2.235186	1.826455	0.011968	0.008976

In [72]:

```
rmse4 = cv_results["test_rmse"].mean()
mae4 = cv_results["test_mae"].mean()
accuracy = update_accuracy(accuracy, "means", rmse4, mae4)
```

Surprise KNNBasic con Similarità Coseno title-based

Si ripete l'analisi precedente con similarità coseno con approccio title-based.

In [73]:

```
from surprise import KNNBasic
model = KNNBasic(k=10, sim_options={"name": "cosine", "user_based": False})
cv_results = cross_validate(model, data, cv=kf)
```

```
Computing the cosine similarity matrix...
Done computing similarity matrix.
Computing the cosine similarity matrix...
Done computing similarity matrix.
Computing the cosine similarity matrix...
Done computing similarity matrix.
Computing the cosine similarity matrix...
Done computing similarity matrix.
Computing the cosine similarity matrix...
Done computing similarity matrix.
```

In [74]:

```
model.fit(data_train)
pred = model.test(data_test)
rmse(pred), mae(pred)
```

```
Computing the cosine similarity matrix...
Done computing similarity matrix.
RMSE: 2.2198
MAE:  1.8273
```

Out[74]:

```
(2.219765287375118, 1.8272591015682624)
```

In [75]:

```
pd.DataFrame(cv_results)
```

Out[75]:

	test_rmse	test_mae	fit_time	test_time
0	2.186788	1.793012	0.743012	0.025931
1	2.041933	1.662680	0.735036	0.026926
2	2.249103	1.894243	0.689160	0.026926
3	2.280825	1.859789	0.500663	0.028922
4	2.163438	1.785451	0.681177	0.030918

In [76]:

```
rmse5 = cv_results["test_rmse"].mean()
mae5 = cv_results["test_mae"].mean()
accuracy = update_accuracy(accuracy, "title-based", rmse5, mae5)
```

Surprise con NormalPredictor

In [77]:

```
from surprise import NormalPredictor
model = NormalPredictor()
cv_results = cross_validate(model, data, cv=kf)
```

In [78]:

```
model.fit(data_train)
pred = model.test(data_test)
rmse(pred), mae(pred)
```

```
RMSE: 3.0022
MAE:  2.3908
```

Out[78]:

```
(3.0022448958538415, 2.3907656437705693)
```

In [79]:

```
pd.DataFrame(cv_results)
```

Out[79]:

	test_rmse	test_mae	fit_time	test_time
0	2.853079	2.311910	0.002990	0.006983
1	2.898911	2.344261	0.006981	0.011967
2	2.996114	2.459740	0.004984	0.006982
3	3.180743	2.582140	0.003990	0.008976
4	2.839768	2.302789	0.004988	0.013962

In [80]:

```
rmse6 = cv_results["test_rmse"].mean()
mae6 = cv_results["test_mae"].mean()
accuracy = update_accuracy(accuracy, "normal", rmse6, mae6)
```

Surprise con SVD

SVD è una libreria apposita per eseguire un'analisi di recommendation casuale

In [81]:

```
from surprise import SVD
model = SVD(n_factors=5, random_state=42)
cv_results = cross_validate(model, data, cv=kf)
```

In [82]:

```
model.fit(data_train)
pred = model.test(data_test)
rmse(pred), mae(pred)
```

```
RMSE: 2.1727
MAE:  1.7872
```

Out[82]:

```
(2.1726940756892485, 1.787161862653741)
```

In [83]:

```
pd.DataFrame(cv_results)
```

Out[83]:

	test_rmse	test_mae	fit_time	test_time
0	2.090797	1.702945	0.064826	0.019949
1	2.029881	1.637338	0.082779	0.005983
2	2.178510	1.812346	0.064827	0.008976
3	2.221496	1.794470	0.070810	0.004987
4	2.106561	1.739308	0.069813	0.008977

In [84]:

```
rmse7 = cv_results["test_rmse"].mean()
mae7 = cv_results["test_mae"].mean()
accuracy = update_accuracy(accuracy, "SVD", rmse7, mae7)
```

Valutazione dei modelli

Grafico di confronto trai i valori RMSE e MAE riportati dai modelli di recommendation

In [85]:

```
accuracy.set_index("model", inplace=True)
```

In [86]:

```
accuracy.sort_values("RMSE").plot.bar(figsize=(10,5));
```

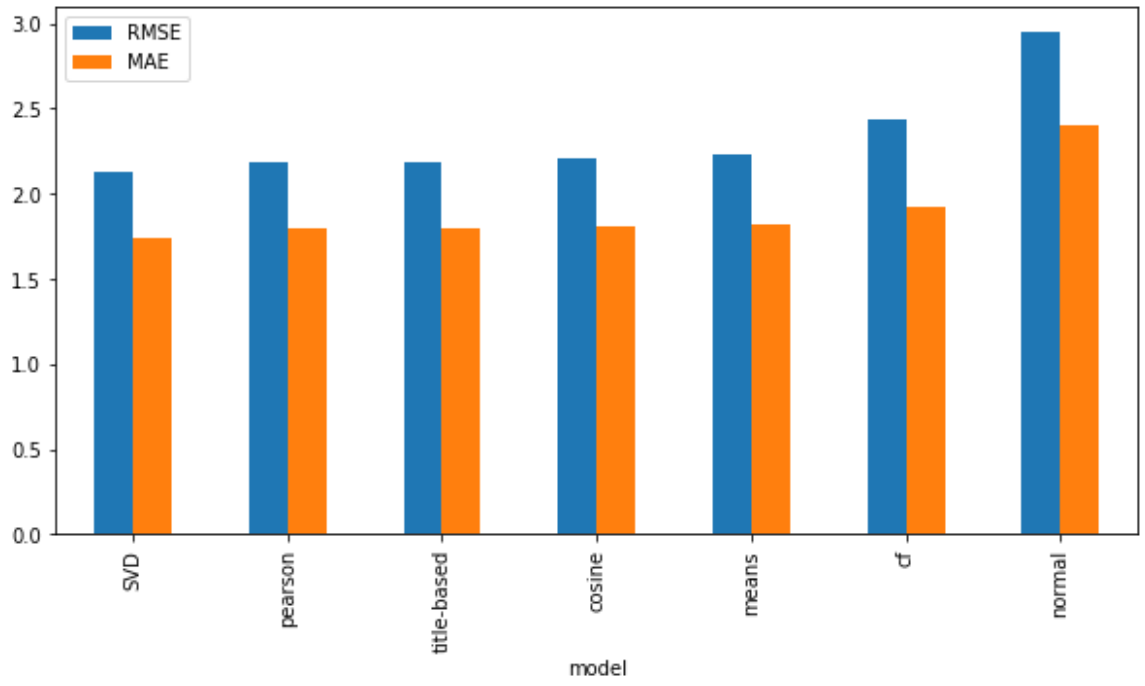

In [87]:

```
accuracy.sort_values("RMSE").T
```

Out[87]:

model	SVD	pearson	title-based	cosine	means	cf	normal
RMSE	2.125449	2.178876	2.184417	2.207117	2.231074	2.440524	2.953723
MAE	1.737281	1.791964	1.799035	1.812112	1.820126	1.917943	2.400168

Dei modelli studiati quello che risulta con un'accuratezza migliore in termini di RMSE e MAE è SVD.

Ricerca del modello migliore

Grid Search

Grid Search si utilizza per individuare i parametri migliori per il modello in questione.

In [88]:

```
from surprise.model_selection import GridSearchCV
```

In [89]:

```
grid = {
    "n_factors": list(range(5,50,5)),
    'n_epochs':[20,30],
    'random_state': [42],
    'lr_all':[0.01],
    'reg_all':[0.1]
}
```

In [90]:

```
gs = GridSearchCV(SVD, grid, cv=kf, refit=True)
gs.fit(data)
```

In [91]:

```
gs.best_params
```

Out[91]:

```
{'rmse': {'n_factors': 20,
  'n_epochs': 20,
  'random_state': 42,
  'lr_all': 0.01,
  'reg_all': 0.1},
 'mae': {'n_factors': 15,
  'n_epochs': 30,
  'random_state': 42,
  'lr_all': 0.01,
  'reg_all': 0.1}}
```

In [92]:

```
pd.DataFrame(gs.cv_results).sort_values("mean_test_rmse")
```

Out[92]:

	split0_test_rmse	split1_test_rmse	split2_test_rmse	split3_test_rmse	split4_test_rmse	me
6	2.079381	2.036058	2.184443	2.213255	2.098345	
4	2.075452	2.036778	2.181014	2.221762	2.097551	
16	2.085567	2.035662	2.183650	2.214156	2.098188	
10	2.082375	2.034160	2.184600	2.215683	2.100431	
7	2.078122	2.042525	2.190133	2.211964	2.098619	
17	2.084146	2.037313	2.187406	2.212599	2.100254	
5	2.070351	2.042012	2.185808	2.223534	2.100310	
11	2.081852	2.036212	2.188242	2.215775	2.102617	
2	2.080750	2.043560	2.184666	2.217967	2.099005	
0	2.081126	2.040861	2.182712	2.214909	2.106993	
14	2.085039	2.036966	2.187834	2.222624	2.103590	
12	2.084654	2.032794	2.192688	2.220954	2.107116	
8	2.085743	2.031379	2.188362	2.220619	2.113758	
3	2.077603	2.054445	2.191375	2.219915	2.100557	
15	2.085516	2.040522	2.192995	2.223602	2.105012	
13	2.085598	2.034520	2.199322	2.220881	2.108797	
9	2.086525	2.031372	2.193558	2.222417	2.119188	
1	2.080183	2.055134	2.191870	2.216219	2.120108	

18 rows × 26 columns

Si calcola RMSE e MAE sul validation set del modello migliore individuato

In [93]:

```
preds = gs.test(data_test)
rmse(preds), mae(preds)
```

```
RMSE: 1.0883
MAE:  0.8502
```

Out[93]:

```
(1.088255573660189, 0.8502113590747339)
```

Si definisce una funzione Recommend che prende in input l'indice numerico di un utente e che restituisce una lista dei film con valutazione più simile alle sue

In [94]:

```
def recommend(uid, n_recomms):
    user_id = user_ratings["user_id"].unique()[uid]
    preds = [gs.predict(user_id, data_train.to_raw_iid(ii))
             for ii in range(data_train.n_items)]
    preds.sort(key=lambda p: p.est, reverse=True)
    return pd.DataFrame([(p.iid, p.est) for p in preds[:n_recomms]], columns=["title",
"rating"])
```

In [95]:

```
recommend(400, 10)
```

Out[95]:

	title	rating
0	The Matrix	7.916165
1	The Sixth Sense	7.840697
2	South Park: Bigger, Longer & Uncut	7.590330
3	Crouching Tiger, Hidden Dragon	7.418708
4	Saving Private Ryan	7.372068
5	Breaking the Waves	7.367003
6	Being John Malkovich	7.343556
7	The Lord of the Rings: The Fellowship of the Ring	7.339380
8	Rush Hour	7.310901
9	Buffalo '66	7.284532

Conclusioni

In conclusione ritengo soddifacente l'accuratezza raggiunta dal modello di valutazione, grazie a questi modelli è stato possibile effettuare uno studio e un'analisi sul dataset, con lo scopo di ottenere una previsione approssimativa dei film da consigliare ad un utente in base al suo profilo di valutazioni.